

Proyecto 1 (15%)
Probabilidad y Estadística
Bioingeniería
2026-1

Descripción de la base de datos

En este proyecto se utilizará la base de datos de PhysioNet titulada “*Visceral adipose tissue measurements during pregnancy*”. Esta base corresponde a un estudio de cohorte realizado en mujeres embarazadas (≤ 20 semanas de gestación) que fueron seguidas hasta el momento del parto.

La base de datos contiene información clínica y antropométrica de 133 pacientes en las siguientes variables:

- ethnicity: ethnicity (0 = white; 1 = not white).
- mean diastolic bp: mean diastolic blood pressure in mmhg.
- mean systolic bp: mean systolic blood pressure in mmhg.
- central armellini fat (mm): maternal visceral adipose tissue measurement in mm.
- pregnancies (number): number of pregnancies.
- bmi pregestational (kg/m): pregestational body mass index.
- child birth weight (g): birthweight in grams.
- gestational dm (current gestational diabetes): 0 = no; 1 = yes.

Procedimiento

Cargue los datos como un DataFrame.

- **(20%)** Realice un análisis exploratorio de las variables numéricas. Cada ítem desarróllelo en una celda de código independiente, y seguidamente analice o describa lo obtenido en una celda de texto.
 - Determine la presencia de datos atípicos usando un diagrama de cajas y bigotes.
 - En el caso de haber datos ausentes, elimine estas filas, o reemplácelos por la media o la mediana, justifique.
 - Describa el tipo de distribución que siguen las variables.
 - Determine para cada variable si los datos presentan variabilidad alta, moderada o baja. Describa qué implicaciones tiene el tipo de variabilidad obtenida.
 - Determine qué variables están relacionadas, además indique según la literatura si estas relaciones tienen sentido o si son relaciones espurias. (Esto implica citar y referenciar apropiadamente)

De las variables categóricas realice una descripción según lo estudiado en clase.

- **(70%)** Para cada variable numérica, determine si existe diferencia estadística entre: mujeres blancas y no blancas, primíparas y multíparas, y mujeres con diabetes gestacional o no. Para esto deberá separar el DataFrame en dos para cada comparación pedida según la variable indicada previamente (blancas o no, primíparas o no...). Se espera que realicen los análisis comparativos de forma separada, es decir, primero se debe hacer el análisis completo entre mujeres blancas y no blancas, luego el siguiente y así sucesivamente, para cada análisis comparativo pedido se pide lo siguiente (cada ítem desarróllelo de forma separada, bien sea en código seguido de celda de texto, o solo en celda de texto según corresponda)
 - (5%) Elija una prueba estadística paramétrica, justifique.
 - (5%) Plantee las hipótesis de la prueba, en términos del contexto específico (esto se hace para todas las pruebas que harán)
 - (10%) Corrobore los supuestos necesarios para la prueba paramétrica seleccionada. Plantee las hipótesis de estas pruebas.
 - (20%) Si no se cumple el supuesto de normalidad u homocedasticidad, realice una transformación apropiada.
 - (10%) Corrobore los supuestos luego de la transformación.
 - (20%) Una vez Cumplidos los supuestos, aplique la prueba e imprima el valor p. Si en este punto no se logró cumplir los requisitos de la prueba paramétrica, elija una alternativa no paramétrica, aplíquela e imprima el valor p.
- (10%) Saque las conclusiones de cada análisis comparativo

Entregable

Deberá entregar un archivo tipo notebook (.ipybn) con el desarrollo de la actividad. **Sea muy organizado**, haga uso de celdas de texto y de código de forma separada para **mostrar paso a paso lo que hace y lo que significa cada resultado para finalmente llegar a una conclusión**. Lo más importante del proyecto es la interpretación de los resultados, por lo que se insta a no ser muy escueto en las descripciones, de lo contrario se verá reflejado en el desempeño del trabajo. Procure no realizar códigos muy largos, es preferible hacer códigos cortos, he ir analizándolos uno a uno en celdas de texto independientes.